

بسمه تعالی

شماره:

طرح تحقیق پایان نامه / رساله
(پیشنهاد)

تاریخ:

۱- مشخصات دانشجو

نام و نام خانوادگی : سینا سپهوند	شماره دانشجویی : ۴۰۳۲۹۰۴۰۰۱
رشته تحصیلی : کامپیوتر گرایش : هوش مصنوعی	مقطع تحصیلی: کارشناسی ارشد
آدرس و تلفن : ۰۹۹۹۹۹۷۹۲۵۹	

۲- عنوان پایان نامه / رساله

۲-۱- عنوان فارسی: تحلیل احساسات بازار سرمایه ایران با داده های شبکه های اجتماعی
۲-۲- عنوان انگلیسی: Analyzing Iranian capital market sentiment with social media data

۳- مشخصات استادان راهنما و مشاور

محل اشتغال	مرتبه علمی	نام و نام خانوادگی	مسئولیت
		دکتر فاطمه عظیم زاده	استاد راهنما
			*استاد مشاور اول(حسب مورد)
			*استاد مشاور دوم(حسب مورد)

برگ بررسی پیشنهاد پایان نامه / رساله در شورای تخصصی گروه

پیشنهاد پایان نامه آقای سینا سپهوند دانشجوی رشته هوش مصنوعی مقطع کارشناسی ارشد به شماره دانشجویی ۴۰۳۲۹۰۴۰۰ با عنوان در تاریخ در
ورای تخصصی گروه مطرح، و پس از شنیدن دفاعیه دانشجو، نظر شورا به شرح ذیل اعلام گردید:

☐ نیاز به اصلاح دارد

☐ تصویب نشد

☐ تصویب شد

اسامی و امضاء اعضای شورای تخصصی گروه

- | | |
|----|----|
| ۱- | ۴- |
| ۲- | ۵- |
| ۳- | ۶- |

مدیر محترم گروه

احتراماً، اصلاحات فوق‌الذکر انجام شد طرح پایان نامه/ رساله‌ی پیوست مشتمل بر صفحه، که کلیه صفحات آن به تایید اینجانب رسیده، کامل می‌باشد.

استاد راهنما

تاریخ و امضاء

مدیر کل محترم تحصیلات تکمیلی

پیشنهاد پایان نامه/ رساله‌ی خانم/آقای با عنوان "....." که بر اساس ضوابط مربوط و مصوبات شورای تحصیلات تکمیلی دانشگاه تنظیم و به تایید شورای تخصصی گروه همچنین استاد راهنما رسیده، جهت تصویب قطعی ایفاد می‌گردد.

مدیر گروه

تاریخ و امضاء

۱ بیان مسئله

بازار سرمایه ایران به سبب سهم بالای سرمایه گذاران حقیقی، سرعت انتشار شایعه و خبر در فضای مجازی، و ناهمگنی سواد مالی، بستری است که در آن احساسات جمعی — همان چرخه ترس و طمع — اثری محسوس بر نوسانات کوتاه مدت قیمت می گذارد. حجم انبوهی از داده متنی غیر ساخت یافته، از تالارهای گفت و گوی بورسی مانند ره آورد ۳۶۵ و ایران سی آر تا کانال های تلگرامی و تحلیل های غیر رسمی، این هیجان جمعی را به صورت لحظه ای بازتاب می دهد. با این حال، هیچ شاخص بومی، روزانه و استاندارد برای سنجش نظام مند این احساسات در دسترس نیست تا تصمیم گیران بتوانند آن را در مدیریت ریسک، زمان بندی معامله و سیاست گذاری به کار گیرند.

اهمیت رفع این کمبود در دو سطح آشکار است. در سطح ملی، یک شاخص بومی ترس و طمع می تواند به مثابه سامانه هشدار زودهنگام رفتاری برای شکنندگی نقدشوندگی، رفتار گله ای و جهش نوسان عمل کند، اثر اطلاعاتیه ها و بخشنامه ها را بر بازار بسنجد و با استاندارد سازی سنج «حال و هوای بازار»، اطلاعات نامتقارن را کاهش دهد و از سرمایه گذار خرد حمایت کند. در سطح علمی، این پژوهش الگویی قابل انتقال برای زبان های کم منبع ارائه می دهد که پیش آموزش تک زبانه، ریزتنظیم کارآمد و چارچوب چندعاملی را در یک دامنه مالی نوظهور ترکیب می کند و زیرساختی باز برای پژوهش های آتی تحلیل احساسات مالی فارسی می سازد. آنچه این ضرورت را برجسته می کند، فاصله میان بلوغ روش های جهانی و فقدان ابزار بومی متناظر در ایران است؛ فاصله ای که در ادامه بر پایه ادبیات موجود صورت بندی می شود.

امضا استاد راهنما

امضا دانشجو

۲ پیشینه پژوهش

آثار مرتبط را می‌توان در چهار دسته سازمان داد؛ این دسته‌بندی هم‌زمان مسیر بلوغ حوزه و مرزهای دانش کنونی را روشن می‌کند.

دسته نخست، تحول روش‌شناختی از واژگان محوری به ترنسفورمرها. مرور جامع Du و همکاران مسیر گذار از روش‌های واژگان محور به مدل‌های ترنسفورمری و دامنه اختصاصی را مستند می‌کند و رابطه احساس سرمایه گذار با احساس بازار را بازتعریف می‌نماید [۱]. این روایت با یافته Sohangir و همکاران هم‌سوست که برتری چشمگیر شبکه‌های عمیق (به‌ویژه CNN^۱) بر پایه‌های سنتی مبتنی بر کیسه واژگان^۲ را نشان می‌دهند [۲].

دسته دوم، مدل‌های زبانی بزرگ دامنه محور مالی. Huang و همکاران با FinBERT نشان دادند بومی‌سازی دامنه، دقت طبقه‌بندی لحن و به‌ویژه تشخیص منفی و پیوند آن با واکنش بازار را به‌طور معنادار تقویت می‌کند [۳]. Wu و همکاران با BloombergGPT اثبات کردند آموزش ترکیبی روی داده دامنه اختصاصی و عمومی، هم‌زمان برتری مالی و حفظ توانمندی عمومی را تأمین می‌کند و اهمیت توکن‌ساز اختصاصی دامنه را برجسته می‌سازد [۴]. Xing نشان داد چارچوب‌های چندعاملی ناهمگن بدون ریزتنظیم می‌توانند فاصله یادگیری در متن^۳ با مدل‌های ریزتنظیم‌شده را تا حد زیادی بکاهند [۷]، و مطالعات مقایسه‌ای جدید جایگاه متمایز FinBERT، GPT-۴ و T۵ را روشن کرده‌اند [۸].

^۱ Convolutional Neural Network

^۲ bag of words

^۳ in-context learning

امضا دانشجو

امضا استاد راهنما

دسته سوم، پیوند احساس با رفتار بازار و اعتبارسنجی اقتصادی. Gurgul و همکاران در حوزه رمزارز نشان دادند صورت‌بندی هدف به صورت نقاط عطف قیمتی بر رگرسیون پیوسته مزیت دارد و سیگنال متن‌محور تا افق هفتگی قابلیت پیش‌بینی نگره می‌دارد [۵]. Ballinari و Maly در بازار ارز با ریزتنظیم کارآمد QLoRA^۴ و تفکیک لحن گذشته‌نگر و آینده‌نگر، به دقتی فراتر از روش‌های واژگانی رسیدند [۶]. Liu و همکاران با ابزارهای اقتصادسنجی، پیوند احساس-قیمت را به صورت کمی اعتبارسنجی و عملیاتی کردند [۹]. این دسته نشان می‌دهد که اعتبارسنجی اقتصادی احساسات رویه‌ای جالفتاده در ادبیات است.

دسته چهارم، پردازش زبان فارسی و کیفیت داده. ParsBERT اثبات کرده که یک مدل تک‌زبان فارسی بر مدل‌های چندزبان برتری معنادار دارد [۱۰]، و Pencheva نشان داده که پایش کیفیت و پاک‌سازی نویز نه یک مرحله جانبی بلکه مؤلفه‌ای محوری از خط‌لوله تحلیل احساسات است [۱۱].

۲/۱ جدول مقایسه‌ی مقالات

مرجع	یافته‌ی کلیدی	وظیفه و معیار ارزیابی	روش و مدل	منبع داده	حوزه و بازار
Sohangir همکاران، ۲۰۱۸، J. of Big Data [8]	CNN با دقت بیش از ۹۰٪ بر روش‌های سنتی مبتنی بر کیسه‌ی واژگان برتری چشمگیر دارد	طبقه‌بندی دوکلاسه‌ی احساس؛ معیار دقت (Accuracy)	یادگیری عمیق CNN؛ doc2vec، LSTM، برابر خطوط پایه‌ی سنتی (مثل SVM)	پیام‌های StockTwits (نیمه‌ی نخست ۲۰۱۵)، برجسب صعودی/نزولی	احساسات مالی، سهام (داده‌ی کلان)
Du [2] و همکاران، ۲۰۲۴، ACM Computing Surveys	مسیر گذار از روش‌های واژگان‌محور به ترنسفورمرها را مستند می‌کند و رابطه‌ی احساس سرمایه‌گذار با احساس بازار را بازتعریف می‌کند	ساخت تاکسونومی دوجریانی (تکنیک‌ها و کاربردها)	مقاله‌ی مروری/تاکسونومی؛ بدون مدل تجربی	مرور بیش از ۲۰۰ مقاله	مرور جامع تحلیل احساسات مالی

⁴ Quantized Low-Rank Adaptation

امضا استاد راهنما

امضا دانشجو

Huang [3] و همکاران، ۲۰۲۳، <i>Contemporary Accounting Research</i>	بومی‌سازی دامنه دقت طبقه‌بندی، به‌ویژه تشخیص منفی، و پیوند آن با واکنش بازار را معنادار بهبود می‌دهد	طبقه‌بندی سه‌کلاسه‌ای لحن + اعتبارسنجی واکنش بازار	(BERT) FinBERT دامنه‌سازگار شده (در برابر ۸ الگوریتم	پیش‌آموزش روی ۴٫۹ میلیارد توکن مالی	NLP مالی، متون مالی حرفه‌ای
Wu [7] و همکاران، ۲۰۲۳، arXiv (BloombergGPT)	آموزش ترکیبی دامنه اختصاصی و عمومی همزمان برتری مالی و حفظ توانمندی عمومی را تأمین می‌کند	وظایف مالی (احساس، NER، پرسش‌وپاسخ (در حالت few-shot	LLM ۵۰ میلیارد پارامتری با توکن‌ساز اختصاصی دامنه؛ آموزش ترکیبی	پیکره‌ی مالی Bloomberg + داده‌ی عمومی	LLM مالی در مقیاس بزرگ
Gurgul [4] و همکاران، ۲۰۲۵، <i>Int. J. of Forecasting</i>	صورت‌بندی هدف به‌صورت نقاط عطف سیگنالی پایدارتر و کم‌نویزتر می‌سازد؛ سیگنال متنی تا افق هفتگی قابل‌پیش‌بینی است	پیش‌بینی نقاط عطف قیمتی (۲۱/۱۴/۷± روز)؛ معیار AUC	ترنسفورمرها-Twitter: BART-، RoBERTa MNLI صفرشات، RoBERTa ریزتنظیم‌شده	۱٫۹~M توپیت، ۳۳۸~K پست Reddit، اخبار، داده‌ی بلاکچین و گوگل‌ترندز	پیش‌بینی رمزارز (BTC، ETH)
Ballinari [1] و Maly، ۲۰۲۵، SNB Working Papers	ریزتنظیم کارآمد بر روش‌های واژگانی و مدل‌های مالی عام برتری دارد؛ تفکیک لحن گذشته/آینده اهمیت دارد	طبقه‌بندی احساس + ساخت استراتژی معاملاتی	Llama 3.1 8B ریزتنظیم‌شده با QLoRA؛ تفکیک لحن گذشته‌نگر/آینده‌نگر	اخبار FX؛ برچسب‌گذاری دوردست + انسانی	بازار ارز (FX)
Xing [9]، ۲۰۲۵، ACM TMIS	عامل‌های ناهمگن نظریه‌مبنا، فاصله‌ی یادگیری-در-متن با مدل‌های ریزتنظیم‌شده را تا حد زیادی می‌کاهند	طبقه‌بندی احساس مالی	چارچوب چندعاملی ناهمگن (HAD) بدون ریزتنظیم	متون مالی معیار	تحلیل احساسات مالی
Seshakagari [10] و همکاران، ۲۰۲۵، <i>Int. J. Human Computations & Intelligence</i>	راهنمایی انتخاب مدل بسته به کاربرد ارائه می‌دهد؛ هر مدل جایگاه متمایزی دارد	طبقه‌بندی احساس؛ موازنه‌ی دقت/تفسیرپذیری/کارایی	مقایسه‌ی FinBERT، T5 و GPT-4؛ تکنیک افزایش داده‌ی احساس‌آگاه (SADA)	پیکره‌های مالی معیار	تحلیل احساسات مالی و پیش‌بینی بازار
Liu [11] و همکاران، ۲۰۲۴، <i>IEEE Access</i>	اعتبارسنجی اقتصادسنجی پیوند احساس-قیمت را برجسته و عملیاتی می‌کند	همبستگی احساس اخبار با قیمت رمزارز	تاکسونومی LLM ها (encoder/enc-dec/decoder)؛ آنترپی انتقالی، DCC-GARCH	مرور + اخبار رمزارز	بازارهای مالی، مطالعه‌ی موردی بیت‌کوین
Pencheva [5]، ۲۰۲۵، <i>SAR Journal</i>	نویز به‌صورت نظام‌مند خروجی احساس را تحریف می‌کند؛ پایش کیفیت باید جزو خطوله باشد، نه مرحله‌ی جانی	سنجش کمی اثر نویز بر توزیع قطبیت	چارچوب پروفایلینگ و تحلیل بصری + VADER	داده‌ی نویزی شبکه‌های اجتماعی	کیفیت داده در تحلیل احساسات

امضا دانشجو

امضا استاد راهنما

Farahani [6] و مدل تک‌زبان فارسی چند وظیفه‌ی NLP BERT تک‌زبان فارسی پیکره‌های عمومی درک زبان همکاران، بر مدل‌های چندزبان فارسی شامل فارسی در برابر فارسی فارسی (فارسی) ۲۰۲۰/۲۰۲۱، برتری معنادار دارد احساس؛ معیار F1 mBERT چندزبان

Neural Processing Letters (ParsBERT)

شکاف داده. هیچ‌یک از یازده اثر، پیکره‌ی برجسته‌شده‌ی فارسی مالی یا واژه‌نامه‌ی بومی بازار ایران ارائه نمی‌دهد. نزدیک‌ترین آثار، [۵] (روش‌شناسی سنجش و پاک‌سازی نویز، قابل‌انتقال به فارسی) و [۶] (پیکره‌ی فارسی عمومی، نه مالی) هستند. این شکاف کاملاً باز است.

شکاف مدل. ادبیات از دو سو به این نقطه نزدیک می‌شود اما آن را پر نمی‌کند: آثار مالی ([۳]، [۷]، [۱]، [۹]، [۱۰]، [۸]) قدرتمند ولی غیرفارسی‌اند، و تنها اثر فارسی ([۶]) غیرمالی است. ترکیب «فارسی + مالی دامنه‌محور» در هیچ منبعی دیده نمی‌شود؛ این دقیقاً جایگاه هدف ۲ پروپوزال است.

شکاف شاخص‌سازی. هیچ اثری شاخص روزانه‌ی ۰ تا ۱۰۰ ترس و طمع با تجمیع چندپلتفرمی و وزن‌دهی پویا نمی‌سازد. [۴] (نقاط عطف) و [۱] (تفکیک گذشته‌نگر/آینده‌نگر) صرفاً مؤلفه‌هایی از این ایده را پوشش می‌دهند.

شکاف اعتبارسنجی اقتصادی [۳]، [۱۱] و [۴] پیوند احساس را با واکنش بازار، قیمت یا بازده می‌سنجند، اما هیچ‌یک به‌طور مشخص احساس را به انحراف قیمت از ارزش ذاتی در بازار ایران گره نمی‌زند؛ این محور هدف ۳ است.

۳ شکاف پژوهشی

جمع‌بندی چهار دسته بالا سه شکاف به‌هم‌پیوسته را در زمینه ایران آشکار می‌کند:

شکاف داده. هیچ‌یک از آثار مرور شده، پیکره برجسته‌شده فارسی مالی یا واژه‌نامه بومی بازار ایران ارائه نمی‌دهد. نزدیک‌ترین آثار، روش‌شناسی سنجش و پاک‌سازی نویز قابل‌انتقال به فارسی [۱۱] و پیکره فارسی عمومی (نه مالی) [۱۰]

امضا استاد راهنما

امضا دانشجو

هستند؛ نگارش‌های محاوره‌ای، فینگلیش^۵، هشتگ‌ها و اختصارهای بازار ایران در هیچ منبع استاندارد پوشش داده نشده‌اند. این شکاف را هدف ۱ پژوهش پر می‌کند.

شکاف مدل. ادبیات از دو سو به این نقطه نزدیک می‌شود اما آن را پر نمی‌کند: آثار مالیِ قدرتمند ([۳]، [۴]، [۷]، [۸]) غیرفارسی‌اند، و تنها اثر فارسیِ شاخص ([۱۰]) غیرمالی است. ترکیبِ «فارسی + مالیِ دامنه‌محور» و نسخه بنچ‌مارک‌شده مدل برای زیرزبانِ مالیِ فارسی در هیچ منبعی دیده نمی‌شود. این شکاف را هدف ۲ پژوهش پر می‌کند.

شکاف شاخص‌سازی. هیچ اثری خروجیِ مدل را به یک شاخص روزانه ۰ تا ۱۰۰ ترس و طمع با تجمیع منبع‌محور و تفکیک لحن گذشته‌نگر و آینده‌نگر تبدیل نمی‌کند؛ آثار موجود تنها مؤلفه‌هایی از این ایده را پوشش می‌دهند: نقاط عطف قیمتی [۵] و تفکیک گذشته‌نگر/آینده‌نگر [۶]. این شکاف را هدف ۳ پژوهش پر می‌کند.

سنجشِ اقتصادیِ پیوندِ احساس با رفتار بازار در این پژوهش به‌عنوان یک شکافِ مستقل مطرح نمی‌شود — چنان‌که دسته سوم ادبیات نشان می‌دهد، این اعتبارسنجی رویه‌ای شناخته‌شده است — بلکه به‌مثابه گامِ روش‌شناختیِ اعتبارسنجی برای سه شکافِ بالا در بازار ایران به کار می‌رود.

۴ پرسش محوری پژوهش

بر این پایه، پرسش محوریِ پژوهش چنین صورت‌بندی می‌شود: چگونه می‌توان با گردآوری و استانداردسازیِ داده متنیِ فارسیِ بازار سرمایه — در فاز نخست از دو تالار ره‌آورد ۳۶۵ و ایران‌سی‌آر — و بومی‌سازیِ روش‌های نوین پردازش زبان

⁵ Finglish

طبیعی، مدلی قابل اتکا برای سنجش احساسات ساخت و خروجی آن را به شاخص روزانه ترس و طمعی تبدیل کرد که پیوند معناداری با رفتار بازار (بازده، نوسان و نقدشوندگی) داشته باشد؟

۵. ضرورت و اهمیت تحقیق

بازار سرمایه ایران به سبب نوسان پذیری بالا، شدت شایعه و خبر در شبکه های اجتماعی و کمبود سنجه های بومی زبان فارسی، نیازمند ابزاری داده محور برای اندازه گیری روزانه احساسات سرمایه گذاران است. ادبیات بین المللی نشان داده که مدل های زبانی دامنه اختصاصی در تحلیل متون مالی برتری معنادار دارند و حتی سیگنال پیش نگر^۶ می سازند؛ اما نبود پیکره فارسی مالی و شاخص بومی ترس و طمع، بهره گیری از این دستاوردها را در ایران محدود کرده است. این پژوهش با ساخت پیکره، بهبود مدل و توسعه شاخص، شکاف «دانش به کاربرد» را پر می کند. اهمیت آن را می توان در چهار سطح دید.

سطح ملی (سازمان بورس و سیاست گذار): شاخص می تواند به مثابه سامانه هشدار زودهنگام رفتاری برای شکندگی نقدشوندگی، رفتار گله ای و جهش نوسان عمل کند، اثر اطلاعاتی و بختنامه ها بر بازار را بسنجد، و با استانداردسازی سنج «حال و هوای بازار»، اطلاعات نامتقارن را کاهش دهد و از سرمایه گذار خرد حمایت کند.

سطح جهانی و علمی: این پژوهش الگویی قابل انتقال برای زبان های کم منبع ارائه می دهد که پیش آموزش تک زبانه، ریزتنظیم کارآمد و چارچوب چندعاملی را در یک دامنه مالی نوظهور ترکیب می کند و زیرساختی باز برای پژوهش های آتی تحلیل احساسات مالی فارسی می سازد.

⁶ Predictive signal

امضا استاد راهنما

امضا دانشجو

۶ اهداف پژوهش

هدف کلی. طراحی، پیاده‌سازی و اعتبارسنجی یک زنجیره بومی «داده، مدل، شاخص» که از متون فارسی مالی در شبکه‌های اجتماعی یک شاخص روزانه ترس و طمع می‌سازد و قدرت پیش‌بینی آن را نسبت به انحراف قیمت از ارزش ذاتی، به‌صورت برون‌نمونه، می‌سنجد. سه هدف اختصاصی زیر این هدف کلی را پشتیبانی می‌کنند:

هدف ۱، داده و واژگان: ساخت یک پیکره^۷ برچسب‌خورده فارسی مالی و یک واژه‌نامه جهت‌وابسته به‌روزشونده، با خط‌لوله هیبرید برچسب‌گذاری که برچسب انسانی، برچسب‌گذاری دوردست^۸، برچسب‌گذاری بین‌زبانی^۹ و نمونه‌برداری فعال^{۱۰} را ترکیب می‌کند.

هدف ۲، مدل و شاخص: ریزتنظیم و بنچ‌مارک^{۱۱} یک مدل احساسات فارسی دامنه‌محور (ParsBERT، QLoRA) و گزینه بین‌زبانی یا چندعاملی) و تبدیل خروجی آن به شاخص روزانه ۰ تا ۱۰۰ با وزن‌دهی پلتفرمی پویا و تفکیک گذشته‌نگر و آینده‌نگر.

هدف ۳، اعتبارسنجی اقتصادی: سنجش توان توضیحی و پیش‌بینی شاخص نسبت به انحراف قیمت از ارزش ذاتی و سنجش‌های ریسک و نقدشوندگی، به‌صورت برون‌نمونه.

⁷ Corpus

⁸ Remote labeling

⁹ Cross language

¹⁰ Active sampling

¹¹ Benchmark

امضا استاد راهنما

امضا دانشجو

۷ پرسش‌ها و فرضیه‌های پژوهش

سه پرسش، هم‌راستا با سه هدف، پژوهش را هدایت می‌کنند.

پرسش ۱: آیا مدل دامنه‌محور فارسی، در کنار برچسب‌گذاری بین‌زبانی، سنجش احساسی قابل‌اتکاتری از نظر پایایی برچسب، F1 و پایداری بین‌پلتفرمی نسبت به خطوط پایه واژگانی و چندزبانه ارائه می‌دهد؟

پرسش ۲: آیا وزن‌دهی پلتفرمی پویا^{۱۲} و تفکیک لحن گذشته‌نگر و آینده‌نگر، قوت پیش‌بینی شاخص را افزایش می‌دهد؟

پرسش ۳: آیا افزایش طمع با بیش‌ارزش‌گذاری و بازده آتی منفی، و افزایش ترس با کم‌ارزش‌گذاری و بازده آتی مثبت همراه است، و این اثر در افق ۱ تا ۷ روز معنادار است؟

این پرسش‌ها بر چهار فرض مستند در ادبیات استوارند: پیش‌نگری احساسات نسبت به بازده و نقاط عطف [۱]، [۵]؛ برتری ترنسفورمرهای بومی‌سازی‌شده^{۱۳} بر روش‌های واژگانی [۶]، [۱]، [۳]؛ مزیت مدل تک‌زبانه فارسی بر مدل‌های چندزبانه [۱۰]؛ و پایداری بیشتر شاخص حاصل از تجمیع چندمنبعی نسبت به اتکا به یک منبع [۶]، [۷].

۸ نوآوری پژوهش

¹² Dynamic platform weighting

¹³ Localized

امضا استاد راهنما

امضا دانشجو

نوآوری این پژوهش بر همان زنجیره روش‌شناختی (نمودار ۱) تعریف می‌شود و در پنج نقطه نمایان است. در لایه داده، مازول مستقل پروفایلینگ^{۱۴} و پایش کیفیت، نویز^{۱۵} متون فارسی را پیش و پس از پاک‌سازی به‌صورت کمی می‌سنجد تا تفکیک‌پذیری قطبیت تضمین شود [۱۱]. در لایه برچسب‌گذاری دو نوآوری کلیدی قرار دارد: نخست، برچسب‌گذاری بین‌زبانی که با مدل‌های بین‌زبانی، برچسب‌های پیکره‌های مالی پرمبوع انگلیسی را به فارسی منتقل می‌کند و کمبود داده برچسب‌خورده فارسی را جبران می‌نماید؛ دوم، واژه‌نامه جهت‌وابسته به‌روزشونده و نسخه‌بندی‌شده که امکان افزودن مستمر اصطلاحات تازه بازار، مانند نمادها و تعبیر محاوره‌ای نوظهور، را بدون بازآموزی کامل مدل فراهم می‌کند و به جابه‌جایی زبان بازار در طول زمان پاسخ می‌دهد. در لایه مدل، راهبرد آموزش ترکیبی در مقیاس متناسب با منابع فارسی با الهام از الگوی [۴] BloombergGPT و نیز توکن‌ساز اختصاصی فارسی-مالی آزموده می‌شود. در لایه شاخص‌سازی، وزن‌دهی پلتفرمی پویا و تفکیک گذشته‌نگر و آینده‌نگر، شاخصی پایدارتر و مقاوم‌تر به نویز می‌سازد. و سرانجام در لایه اعتبارسنجی، پیوند مستقیم احساس با انحراف قیمت از ارزش ذاتی برقرار می‌شود؛ خلأیی که حتی در پژوهش‌های جهانی کمتر به‌صورت بومی بررسی شده است [۳]، [۹].

۹ روش‌شناسی پژوهش

رویکرد پژوهش، طراحی مهندسی یک «مصنوع» و سپس ارزیابی تجربی-کمی آن است. کل فرایند، چنان‌که نمودار ۱ نشان می‌دهد، در پنج لایه پیوسته پیش می‌رود.

¹⁴ Profiling

¹⁵ Noise

امضا استاد راهنما

امضا دانشجو

معماری روش شناختی پژوهش: زنجیره داده، مدل، شاخص و اعتبارسنجی

★ = نقاط نوآوری پژوهش

لایه ۱ - داده و کیفیت

گردآوری چندپلتفرمی: تلگرام مالی، تالار ره‌آورد ۳۶۵، انجمن ایرانی سی‌آر [۹، ۱]

نرمال‌سازی فارسی، حذف اسبوم/ریات، نگاشت نماد/صنعت، هم‌ترازی زمانی

★ مازول مستقل پروفایلینگ و پایش کیفیت داده (سنجش نویز پیش و پس از پاک‌سازی) [۵]

لایه ۲ - برجسب‌گذاری و واژگان

برجسب انسانی (کاپای کوهن ≤ ۰.۷۵)، برجسب‌گذاری دوردست، نمونه‌برداری فعال [۱]

★ برجسب‌گذاری بین‌زبانی: انتقال برجسب از پیکره‌های مالی انگلیسی به فارسی [۶]

★ واژه‌نامه جهت‌وابسته به‌روزشونده و نسخه‌بندی‌شده (افزودن مستمر اصطلاحات بازار) [۲]

لایه ۳ - مدل‌سازی زبانی

خطوط پایه و بنچ‌مارک مقایسه‌ای: واژگانی و SVM/لجستیک [۸، ۳، ۱۰]

مدل اصلی: ریزتنظیم [۶] ParsBERT

گزینه‌های کم‌منبع: [۱] QLoRA، چندعاملی ناهمگن [۹]، آموزش ترکیبی و توکن‌سار [۷]

ترکیب‌گر (Ensemble) و کالیبراسیون: پیش‌بینی نقاط عطف قیمتی با معیار AUC [۲]

لایه ۴ - شاخص‌سازی و تجمیع

امتیاز احساس پیام، سپس تجمیع نماد/صنعت/بازار و مقیاس‌بندی ۰ تا ۱۰۰

★ وزن‌دهی پلتفرمی پویا بر مبنای کیفیت سیگنال هر منبع [۹، ۱]

تفکیک گذشته‌نگر/آینده‌نگر، هموارسازی و تشخیص رژیم‌های ترس/طمع [۴، ۱]

لایه ۵ - اعتبارسنجی اقتصادی

گرنجر-علیت، تحلیل رویداد، فاما-مکبث، پرتفوی Long-Short و آزمون برون‌نمونه [۴، ۱۱]

★ پیوند مستقیم احساس با انحراف قیمت از ارزش ذاتی [۱۱، ۳]

(طمع: بیش‌ارزش‌گذاری و بازده آتی منفی؛ ترس: کم‌ارزش‌گذاری و بازده آتی مثبت)

خروجی: شاخص روزانه ترس-طمع، داشبورد API و پیکره و واژه‌نامه باز و بازتولیدپذیر

امضا استاد راهنما

امضا دانشجو

نمودار ۱. معماری روش شناختی پژوهش و نقاط نوآوری

لایه نخست، داده و کیفیت، با گردآوری نرخ محدود از کانال های تلگرامی مالی، تالار ره آورد ۳۶۵ و انجمن ایرانی سی آر آغاز می شود؛ تنها محتوای عمومی و با رعایت ملاحظات حقوقی و حریم خصوصی. سپس نرمال سازی^{۱۶} فارسی (یکنواخت سازی «ی» و «ک»، نیم فاصله، اعداد و امل)، تشخیص و حذف اسپم^{۱۷} و ربات^{۱۸}، نگاشت متن به نماد و صنعت، و هم تراز می مهر زمانی با تقویم معاملاتی انجام می گیرد. یک ماژول مستقل، کیفیت داده را پیش و پس از پاک سازی پیش می کند.

لایه دوم، برچسب گذاری و واژگان، طرحواره برچسب را بر سه محور قطبیت (مثبت، منفی، خنثی با جهت وابستگی محتوایی)، زمان نگری (گذشته نگر و آینده نگر) و شدت بنا می کند، با کنترل کیفیت و توافق میان برچسب گذاران در سطح کاپای کوهن دست کم^{۱۹} ۰/۷۵. برای جبران کمبود برچسب، سه سازوکار ترکیب می شوند: برچسب گذاری دوردست بر مبنای بازده های پنجره ای، برچسب گذاری بین زبانی برای انتقال از پیکره های انگلیسی، و نمونه برداری فعال برای انتخاب هوشمند نمونه های نامطمئن. هم زمان، واژه نامه جهت وابسته به روزشونده ساخته و نگهداری می شود.

لایه سوم، مدل سازی زبانی، از خطوط پایه واژگانی و SVM یا لجستیک^{۲۰} آغاز و به ریزتنظیم ParsBERT می رسد. گزینه های کم منبع شامل QLORA، مدل بین زبانی و چارچوب چند عاملی ناهمگن آزموده می شوند و خروجی ها با یک ترکیب گر (Ensemble) و کالیبراسیون احتمال^{۲۱} تثبیت می گردند. هدف های یادگیری عبارت اند از طبقه بندی سه کلاسه

¹⁶ Normalization

¹⁷ Spam

¹⁸ Robot

¹⁹ Minimum Cohen's kappa level

²⁰ Logistic

²¹ Probability calibration

امضا استاد راهنما

امضا دانشجو

قطبیت با معیار $Macro-F1$ و پیش‌بینی نقاط عطف قیمتی با معیار AUC . برای پرهیز از نشت زمانی، تقسیم زمان‌مبنای داده و ارزیابی نوردی (Walk-forward) به کار می‌رود.

لایه چهارم، شاخص‌سازی، امتیاز احساس هر پیام را با وزن اطلاعاتی و نقشه نماد-صنعت تجمیع می‌کند، وزن هر پلتفرم را به صورت پویا و متناسب با کیفیت سیگنال آن تنظیم می‌نماید، نتیجه را به مقیاس ۰ تا ۱۰۰ می‌برد و با هموارسازی و فیلتر جهش، رژیم‌های ترس و طمع را شناسایی می‌کند. زیرشاخص‌های نماد، صنعت و بازار، و دو نسخه گذشته‌نگر و آینده‌نگر تولید می‌شوند.

لایه پنجم، اعتبارسنجی اقتصادی، با مدل‌های پانل^{۲۲} با اثرات ثابت، آزمون گرنجر علیت^{۲۳}، تحلیل رویداد پیرامون شوک‌های خبری، رگرسیون فاما-مک‌بث^{۲۴} و پرتفوی‌های مرتب‌شده Long-Short (با خنثی‌سازی صنعت و بتا)، رابطه شاخص با بازده، نوسان، نقدشوندگی و به‌ویژه انحراف از ارزش ذاتی را به صورت برون‌نمونه می‌سجد. منافع اقتصادی مانند کاهش بسامد معامله و حساسیت به هزینه تراکنش نیز گزارش می‌شود.

اعتبارسنجی پژوهش در دو سطح انجام می‌شود: اعتبارسنجی مدل و اعتبارسنجی اقتصادی.

الف) اعتبارسنجی مدل. کیفیت برچسب‌ها با توافق میان برچسب‌گذاران در سطح کاپای کوهن دست‌کم ۰.۷۵ کنترل می‌شود. عملکرد طبقه‌بندی با معیار $Macro-F1$ برای طبقه‌بندی سه‌کلاسه‌ی قطبیت و معیار AUC برای پیش‌بینی نقاط عطف قیمتی گزارش می‌گردد، و احتمال‌های خروجی با کالیبراسیون تثبیت می‌شوند. برای پرهیز از نشت زمانی

²² Panel models

²³ Granger causality test

²⁴ Fama-MacBeth Regression

امضا دانشجو

امضا استاد راهنما

(Lookahead Bias)، داده به صورت زمان مبنا تقسیم شده و ارزیابی نوردی (Walk-forward) به کار می رود؛ بدین ترتیب مدل تنها بر داده های گذشته آموزش می بیند و بر داده های آتی آزموده می شود.

ب) اعتبارسنجی اقتصادی. توان توضیحی و پیش بینی شاخص ترس و طمع نسبت به بازده، نوسان، نقدشوندگی و به ویژه انحراف قیمت از ارزش ذاتی، به صورت برون نمونه سنجیده می شود. ابزارهای اقتصادسنجی زیر به کار می روند: مدل های پانل با اثرات ثابت برای کنترل ناهمگنی مقطعی؛ آزمون علیت گرنجر برای بررسی پیش نگر زمانی شاخص نسبت به بازده؛ تحلیل رویداد (Event Study) پیرامون شوک های خبری؛ رگرسیون فاما-مکبث برای سنجش قیمت گذاری مقطعی ریسک؛ و پرتفوی های مرتب شده Long-Short با خنثی سازی صنعت و بتا. در کنار معیارهای آماری، منافع اقتصادی عملی مانند کاهش بسامد معامله و حساسیت به هزینه های تراکنش نیز گزارش می شود.

فرضیه ی محوری اعتبارسنجی آن است که افزایش طمع با بیش ارزش گذاری و بازده آتی منفی، و افزایش ترس با کم ارزش گذاری و بازده آتی مثبت همراه است، و این اثر در افق ۱ تا ۷ روز معنادار باقی می ماند.

۱۰ خروجی ها و نوع پژوهش

خروجی های اصلی عبارت اند از پیکره فارسی مالی برچسب خورده و واژه نامه جهت وابسته، مدل احساسات فارسی بهبود یافته با گزارش کامل معیارها، شاخص روزانه ترس و طمع با زیرشاخص ها، گزارش اعتبارسنجی اقتصادسنجی و پرتفوی های آزمایشی، و یک داشبورد و API برای بهره برداران سازمانی و نظارتی، همراه با مستندات بازتولیدپذیر. از نظر طبقه بندی، این پژوهش در هسته خود کاربردی-توسعه ای است، با رویکرد تبیینی-پیش بین و روش شناسی طراحی علم؛ سنجش

امضا دانشجو

امضا استاد راهنما

تجربگی آن کمی و اقتصادسنجی است و دامنه آن بومی (ایران و زبان فارسی) با قابلیت تعمیم محدود به بازارهای مشابه است.

۱۱ تعریف واژه‌های کلیدی (نظری و عملیاتی)

شاخص ترس و طمع. نظری: سنج‌های که حالت هیجانی جمعی بازار را در پیوستار ترس تا طمع نشان می‌دهد. عملیاتی: عددی در بازه ۰ تا ۱۰۰ که از تجمیع امتیازهای احساس پیام‌ها با وزن‌دهی پلتفرمی و هموارسازی به‌دست می‌آید.

تحلیل احساسات مالی. نظری: استخراج جهت‌گیری عاطفی و ارزشی متون نسبت به دارایی یا بازار. عملیاتی: طبقه‌بندی سه‌کلاسه هر پیام به مثبت، منفی یا خنثی با مدل ریزتنظیم‌شده، همراه با احتمال کالیبره‌شده.

انحراف از ارزش ذاتی. نظری: فاصله قیمت بازاری از ارزش بنیادی دارایی (بیش‌ارزش‌گذاری یا کم‌ارزش‌گذاری). عملیاتی: تفاوت قیمت با برآورد ارزش تحلیلی یا سیگنال‌های بنیادی در دسترس، که به‌صورت دوره‌ای محاسبه می‌شود.

برچسب‌گذاری دوردست. نظری: تولید برچسب خودکار بر مبنای پیامدهای مشاهده‌پذیر به‌جای داوری انسانی. عملیاتی: تخصیص برچسب احساس بر اساس بازده‌های پنجره‌ای نماد در روزهای پیرامون انتشار پیام.

برچسب‌گذاری بین‌زبانی. نظری: انتقال دانش برچسب از یک زبان پرمنبع به زبان کم‌منبع. عملیاتی: استفاده از مدل‌های بین‌زبانی برای انتقال برچسب‌های پیکره‌های مالی انگلیسی به نمونه‌های فارسی.

نمونه‌برداری فعال. نظری: انتخاب هدفمند داده‌هایی که بیشترین اطلاع را برای آموزش دارند. عملیاتی: انتخاب نمونه‌های با بالاترین عدم قطعیت مدل (آنتروپی) برای برچسب‌گذاری انسانی افزوده.

امضا استاد راهنما

امضا دانشجو

وزن دهی پلتفرمی پویا. نظری: تخصیص سهم متغیر به هر منبع متناسب با اعتبار سیگنال آن. عملیاتی: تنظیم وزن تلگرام، تالار و انجمن بر مبنای معیارهای کیفیت سیگنال هر پلتفرم در طول زمان.

نقاط عطف قیمتی. نظری: نقاط بازگشت محلی روند قیمت (کف/سقف موضعی). عملیاتی: برچسب گذاری کمینه و بیشینه محلی قیمت در افق ۷ و ۱۴ روز و آموزش مدل برای پیش بینی آنها.

واژه نامه جهت وابسته. نظری: مجموعه ای از واژه ها و عبارتهای مالی که جهت آنها (صعودی/نزولی) وابسته به بافت است. عملیاتی: یک منبع نسخه بندی شده و به روز شونده شامل اصطلاحات بازار (مانند صف خرید، ریزش، پول هوشمند) که امکان افزودن مستمر اصطلاحات تازه را دارد.

۱۲ مراحل و زمان بندی تحقیق

فاز	فعالیت اصلی	بازه زمانی (هفته)
۱	مرور ادبیات، تدوین پروتکل و راهنمای برچسب گذاری، انتخاب کانال ها و تالارها	۳
۲	گردآوری و پاک سازی داده، مازول کیفیت، نگاشت نماد/صنعت، هم ترازای زمانی	۴ تا ۶

امضا دانشجو

امضا استاد راهنما

۳	برچسب گذاری (انسانی، دوردست، بین‌زبانی، فعال) و ساخت واژه‌نامه جهت وابسته	۵ تا ۸
۴	مدل سازی بین‌زبانی، چندعاملی، ترکیب گر، کالیراسیون و ارزیابی	۶ تا ۱۰
۵	ساخت شاخص، وزن دهی پلتفرمی، زیرشاخص‌ها و توسعه داشبورد و API	۲
۶	اعتبارسنجی اقتصادسنجی، پرتفوی‌های آزمایشی، نگارش و تحویل نهایی	۲

۱۳ امکانات، زمان‌بندی و محدودیت‌ها

اجرای پژوهش به یک ایستگاه پردازش گرافیکی یا ابر معادل، ذخیره‌سازی چند ترابایتی، پشته پایتون^{۲۵} و پای‌تورچ^{۲۶}، ابزار برچسب گذاری و زیرساخت کنترل نسخه کد، داده و مدل نیاز دارد. زمان اجرای پیشنهادی حدود شش تا نه ماه است و هزینه‌های اصلی شامل سخت‌افزار یا ابر، نیروی برچسب گذاری و نگهداشت دوره‌ای است. مهم‌ترین محدودیت‌ها عبارت‌اند از کمبود برچسب انسانی، که با برچسب گذاری دوردست و بین‌زبانی و نمونه‌برداری فعال کاهش می‌یابد؛ نویز و ربات پلتفرم‌ها، که با ماژول ضداسپم و هم‌ترازی زمانی مدیریت می‌شود؛ و جابه‌جایی توزیع در طول زمان، که با بازآموزی دوره‌ای و واژه‌نامه به‌روزشونده پاسخ می‌گیرد. تبیین‌پذیری مدل نیز با ویژگی‌های قابل توضیح و بحث چندعاملی تقویت می‌شود.

۱۴ منابع

^{۲۵} Python

^{۲۶} Pytorch

امضا استاد راهنما

امضا دانشجو

- [1] K. Du, F. Xing, R. Mao and E. Cambria, "Financial Sentiment Analysis: Techniques and Applications," ACM Computing Surveys, vol. 56, 2024.
- [2] S. Sohangir, D. Wang, A. Pomeranets and T. Khoshgoftaar, "Big Data: Deep Learning for Financial Sentiment Analysis," Journal of Big Data, 2018.
- [3] A. H. Huang, H. Wang and Y. Yang, "FinBERT: A Large Language Model for Extracting Information from Financial Text," Contemporary Accounting Research, vol. 40, pp. 806–841, 2023.
- [4] S. Wu et al., "BloombergGPT: A Large Language Model for Finance," arXiv preprint arXiv:2303.17564, 2023.
- [5] V. Gurgul, S. Lessmann and W. K. Härdle, "Deep Learning and NLP in Cryptocurrency Forecasting: Integrating Financial, Blockchain, and Social Media Data," International Journal of Forecasting, 2025.
- [6] D. Ballinari and J. Maly, "FX Sentiment Analysis with Large Language Models," SNB Working Papers, Swiss National Bank, 2025.
- [7] F. Xing, "Designing Heterogeneous LLM Agents for Financial Sentiment Analysis," ACM Transactions on Management Information Systems, vol. 16, no. 1, pp. 1–24, 2025.
- [8] R. B. Seshakagari et al., "Dynamic Financial Sentiment Analysis and Market Forecasting through Large Language Models," International Journal of Human Computations & Intelligence, vol. 4, no. 1, 2025.
- [9] C. Liu et al., "Large Language Models and Sentiment Analysis in Financial Markets: A Review, Datasets, and Case Study," IEEE Access, vol. 12, 2024.
- [10] M. Farahani, M. Gharachorloo, M. Farahani and M. Manthouri, "ParsBERT: Transformer-based Model for Persian Language Understanding," Neural Processing Letters, vol. 53, pp. 3831–3847, 2021.
- [11] D. Pencheva, "Profiling Noisy Social Media Data for Sentiment Applications: A Visual and Analytical Framework," SAR Journal, vol. 8, no. 3, pp. 213–224, 2025.

امضا استاد راهنما

امضا دانشجو



دانشگاه علم و فرهنگ

مرکز تحقیقاتی
ادست آموزشی و تحصیلات تکمیلی
اداره کل تحصیلات تکمیلی

فرم ۰۱/پ

امضا دانشجو

امضا استاد راهنما